SCOUTING DE FUTBOLISTAS MEDIANTE ANÁLISIS DE DATOS:

Identificación de perfiles para delantero centro

Autor: [Yeray Martínez Acha]

Fecha: [Marzo, 2026]

Índice

1. Contexto 4
1.1 Scouting de delanteros 4
2. Objetivo del proyecto 4
3. Descripción del Data Set 4
4. Exploratory Data Analysis del delantero 6
4.1 Boxplots variables filtro 6
4.2 Boxplots variables de orientación ofensiva comparadas con la variable creada es delantero 6
5. Análisis delantero 7
5.1 Regresión logística 8
5.2 Matriz de correlaciones 8
5.3 K-Means 9
5.4 PCA (Análisis de componentes principales) 10
6. Conclusiones 12

1. Contexto

En este proyecto se simula el trabajo del departamento de scouting del Real Madrid CF, con el objetivo de identificar posibles candidatos a una posición clave del equipo: delantero centro. El análisis se basa en datos estadísticos de jugadores de las cinco grandes ligas europeas durante la temporada 2024/2025, incluyendo métricas relacionadas con producción ofensiva, generación de ocasiones y progresión del balón

1.1 Scouting de delanteros

El objetivo es identificar delanteros centro tops mundiales con alta producción ofensiva.

Para ello intentaran detectar aquellas variables donde los delanteros destaquen. Posteriormente se aplica un modelo de segmentación utilizando K-means clustering, que permite agrupar a los delanteros según su nivel de producción ofensiva.

El objetivo es identificar el grupo de jugadores con mayor rendimiento ofensivo y analizar los candidatos más prometedores dentro de ese segmento. mediocampistas con un perfil estadístico comparable

2. Objetivo del proyecto

Demostrar cómo el análisis de datos puede utilizarse para apoyar el proceso de scouting, permitiendo:

- identificar perfiles de jugadores específicos
- reducir el número de candidatos potenciales
- apoyar la toma de decisiones en el mercado de fichajes.

3. Descripción del Data Set

El dataset muestra las estadísticas de todos los jugadores de las 5 grandes de ligas a través de las siguientes variables:

- Player: The name of the player.
- Nation: The player's nationality.
- Pos: The player's position (e.g., forward, midfielder, defender).
- Age: The player's age.
- MP (matches played): Total matches played number
- Starts: Number of matches the player started.
- Min (Minutes): Total minutes played by the player (this might be the same as MP).

- 90s (90s Played): The equivalent of 90-minute matches played by the player (e.g., 1.5 = 135 minutes).
- Gls (Goals): Total number of goals scored by the player.
- Ast (Assists): Total number of assists made by the player.
- G+A (Goals + Assists): Total number of goals and assists combined.
- G-PK (Goals - Penalty Kicks): Total number of goals scored excluding penalty kicks.
- PK (Penalty Kicks): Number of penalty goals scored by the player.
- PKatt (Penalty Kicks Attempted): Number of penalty kicks attempted by the player.
- CrdY (Yellow Cards): Number of yellow cards received by the player.
- CrdR (Red Cards): Number of red cards received by the player.
- xG (Expected Goals): The expected number of goals from the player's shots.
- npxG (Non-Penalty Expected Goals): Expected goals excluding penalties.
- xAG (Expected Assists): The expected number of assists from the player's passes.
- npxG+xAG (Non-Penalty xG + xAG): Total of non-penalty expected goals and expected assists.
- PrgC (Progressive Carries): Number of times the player carried the ball forward.
- PrgP (Progressive Passes): Number of passes made by the player that moved the ball forward.
- PrgR (Progressive Runs): Number of times the player made runs forward with the ball.
- Gls (Goals): (Repeated, already defined) Total number of goals scored.
- Ast (Assists): (Repeated, already defined) Total number of assists made.
- G+A (Goals + Assists): (Repeated, already defined) Total number of goals and assists combined.
- G-PK (Goals - Penalty Kicks): (Repeated, already defined) Goals scored excluding penalty kicks.
- G+A-PK (Goals + Assists - Penalty Kicks): Total goals and assists minus penalty goals.
- xG (Expected Goals): (Repeated, already defined) Expected number of goals from the player's shots.
- xAG (Expected Assists): (Repeated, already defined) Expected number of assists from the player's passes.
- xG+xAG (Expected Goals + Expected Assists): Total expected goals and assists.
- npxG (Non-Penalty Expected Goals): (Repeated, already defined) Expected goals excluding penalties.

- npxG+xAG (Non-Penalty xG + Expected Assists): Total of non-penalty expected goals and expected assists.

4. Exploratory Data Analysis del delantero

4.1 Boxplots variables filtro

Como el club ha pedido un delantero menor de 29 años, que contenga un impacto inmediato se van a filtrar para el modelo las variables Age, Min y 90s. Como la edad ya la sabemos, para poner el límite sobre el que nos vamos a quedar con las variables Min y 90s, se han realizado boxplots para detectar la mediana, y filtrar el dataset con aquellos delanteros que estén por encima de la mediana.

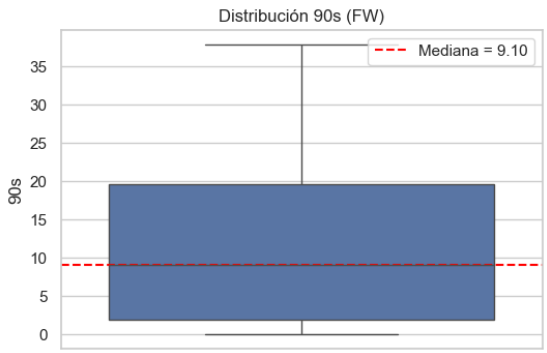

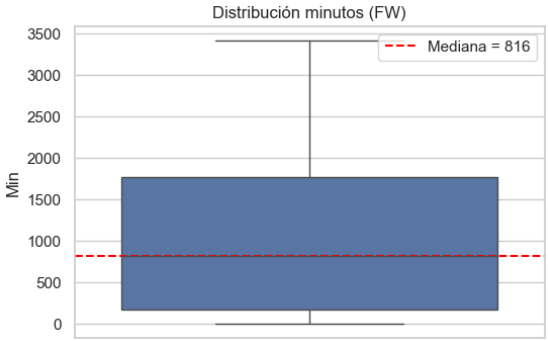

Como se puede observar, se filtrarán en el dataset aquellos delanteros que tengan disputados, la temporada anterior, más de 9 partidos, y que hayan jugado más de 816 minutos.

4.2 Boxplots variables de orientación ofensiva comparadas con la variable creada es delantero

Con el objetivo de identificar qué métricas diferencian el perfil ofensivo de los jugadores, se realiza un análisis exploratorio comparando las principales variables de rendimiento entre atacantes y no atacantes. Para ello, se construye una variable binaria que distingue a los jugadores cuya posición corresponde a los delanteros del data set frente al resto de posiciones. Comparando las medianas, podremos ver si el hecho de ser delantero te hace destacar más dentro de las variables seleccionadas.

El objetivo de este análisis no es únicamente descriptivo, sino que sirve como paso previo a la selección de variables, permitiendo identificar aquellas métricas que presentan un mayor poder discriminativo entre roles ofensivos y no ofensivos.

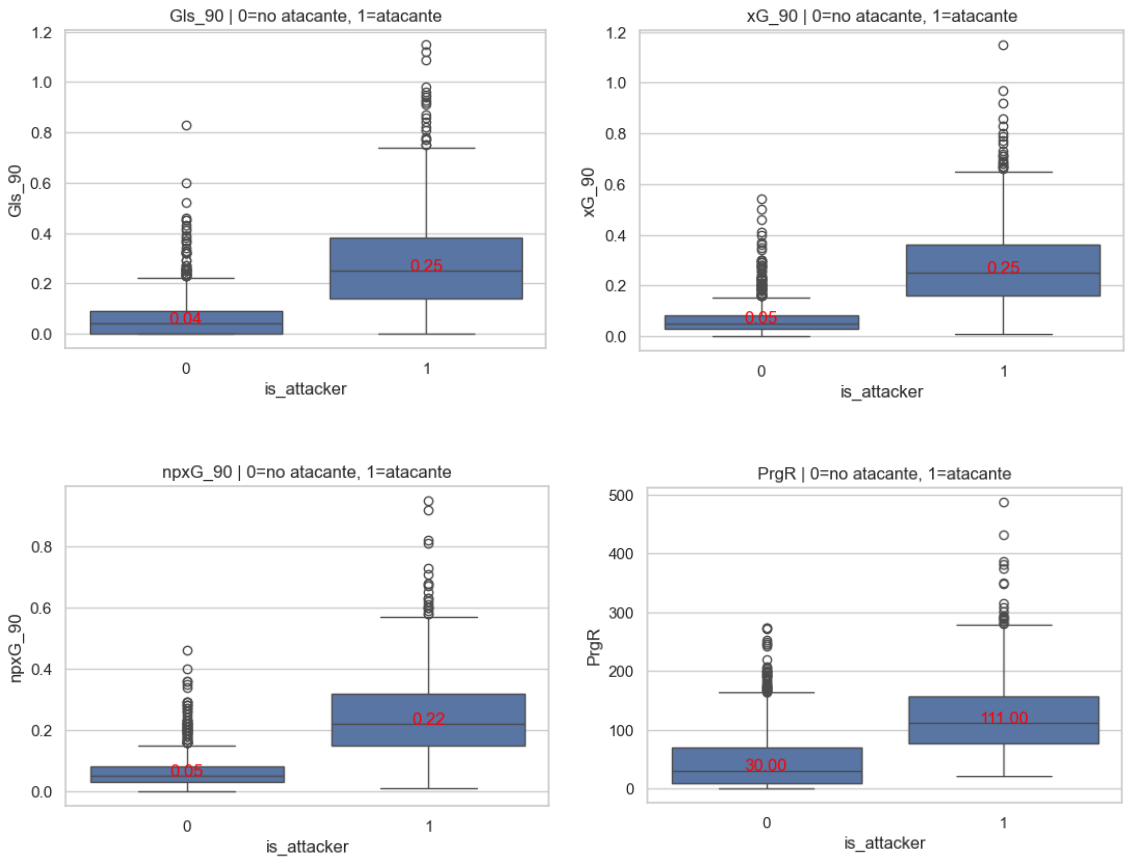

A través de los diagramas de caja se puede dilucidar que:

- Los atacantes presentan medianas claramente superiores en todas las métricas (Gls_90, xG_90, npxG_90 y PrgR), lo que confirma su mayor impacto ofensivo respecto al resto de jugadores.
- Las diferencias son especialmente pronunciadas en producción y generación de ocasiones, donde prácticamente no hay solapamiento entre grupos.
- Además, la mayor dispersión en atacantes indica la existencia de distintos perfiles ofensivos, desde jugadores medios hasta élite.

5. Análisis delantero

Con el objetivo de identificar perfiles de delanteros con alto rendimiento ofensivo, el análisis se estructura en dos enfoques complementarios: un análisis supervisado y un análisis no supervisado.

En primer lugar, se aplica un modelo de regresión logística como técnica supervisada, con el fin de identificar qué variables están más asociadas al rol ofensivo de los jugadores. Este enfoque permite evaluar la relevancia de cada métrica en un contexto multivariable, superando las limitaciones del análisis exploratorio previo y proporcionando una base sólida para la selección de variables.

Posteriormente, se emplea un modelo de clustering (K-means) como técnica no supervisada, cuyo objetivo es agrupar a los jugadores en función de sus características ofensivas, sin imponer una estructura previa. A diferencia del análisis supervisado, que se centra en explicar un rol concreto, el clustering permite descubrir patrones y perfiles de jugadores dentro del conjunto de delanteros.

La combinación de ambos enfoques responde a una lógica metodológica clara: el análisis supervisado se utiliza para seleccionar y justificar las variables más relevantes, mientras que el análisis no supervisado permite identificar grupos homogéneos de jugadores con características similares. De este modo, se garantiza que el clustering se realice sobre variables previamente validadas, mejorando la interpretabilidad y la calidad de los resultados obtenidos.

5.1 Regresión logística

El modelo de regresión logística presenta una accuracy del 87% y un ROC AUC de 0.95, lo que indica una alta capacidad para discriminar entre jugadores atacantes y no atacantes.

Variables

variable	importance
PrgP	1.464500
npxG_90	1.173138
xAG_90	0.939966
PrgR	0.901618
PrgC	0.848093
xG_90	0.720624
Ast	0.533354
G+A	0.475918
xG	0.399869
Gls_90	0.338999
Gls	0.338834
G+A_90	0.205039
npxG	0.163965
xAG	0.126189
Ast_90	0.100442

Las variables más relevantes están relacionadas principalmente con la progresión (PrgP, PrgR, PrgC) y la generación de ocasiones (npxG_90, xAG_90), lo que indica que el rol ofensivo no se define únicamente por la finalización, sino por la participación activa en la construcción del juego.

5.2 Matriz de correlaciones

Tras identificar las variables más relevantes mediante regresión logística, se procede a analizar la correlación entre las distintas métricas con el objetivo de detectar posibles redundancias. Este

análisis permite evitar la inclusión de variables altamente correlacionadas en el modelo de clustering, lo que podría distorsionar los resultados.

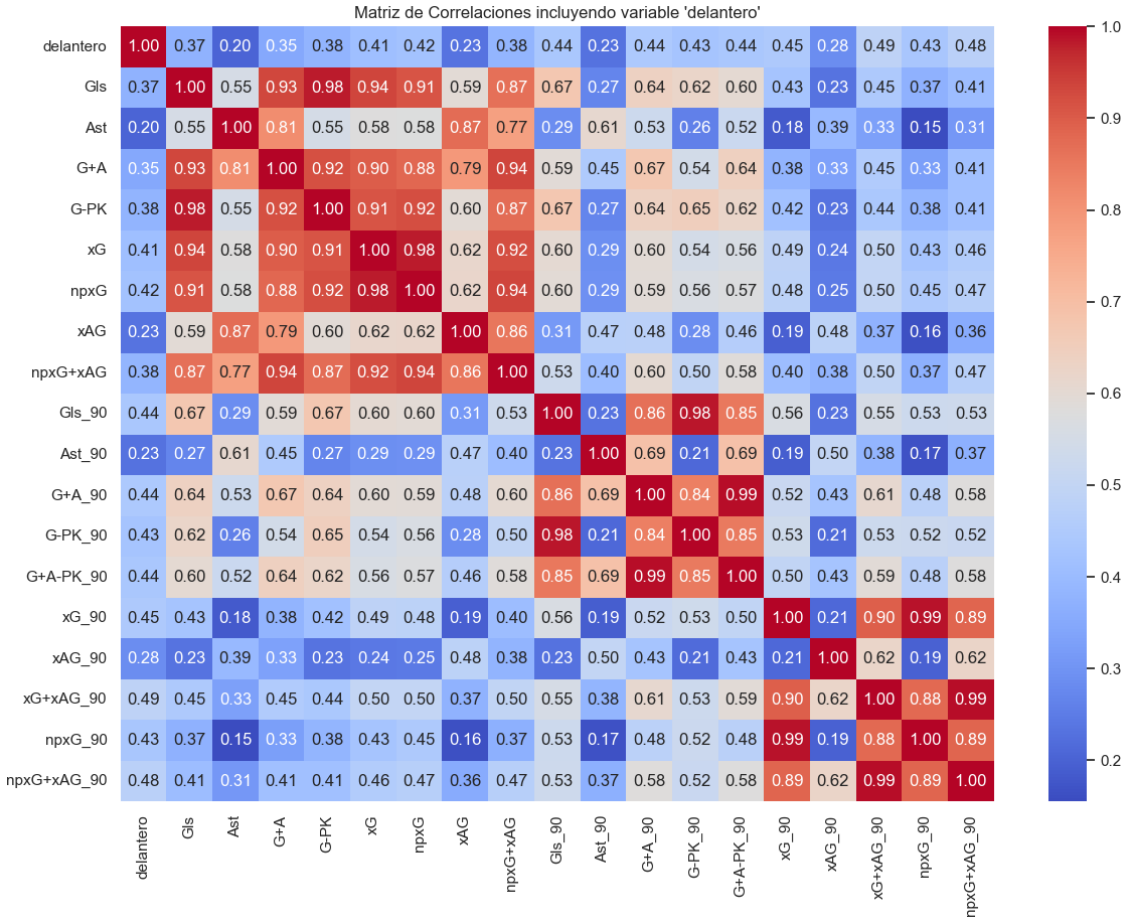

La matriz de correlaciones muestra la existencia de una alta multicolinealidad entre múltiples variables ofensivas, especialmente entre métricas de finalización y generación de ocasiones, así como entre sus equivalentes normalizados por 90 minutos. En particular, variables como xG, npxG y sus versiones por 90 presentan correlaciones cercanas a 1, lo que indica que aportan información redundante.

Por este motivo, se opta por seleccionar un subconjunto reducido de variables que representen distintas dimensiones del juego ofensivo, evitando la duplicidad de información. En concreto, se incluyen métricas de finalización (Gls), creación (Ast, xAG) y progresión (PrgC, PrgP, PrgR), lo que permite capturar el perfil ofensivo de los jugadores de forma completa y eficiente.

5.3 K-Means

A partir de los resultados del modelo, se realiza un proceso de selección de variables que combina la relevancia estadística identificada mediante la regresión logística con un análisis de correlación para evitar redundancias.

De este modo, se selecciona un conjunto final de variables representativas de distintas dimensiones del juego ofensivo: finalización (Gls), creación (Ast, xAG) y progresión (PrgC, PrgP, PrgR). Esta selección permite capturar el perfil ofensivo de los jugadores de forma completa y sin introducir duplicidad de información en el modelo de clustering.

El análisis de clustering mediante K-means muestra que la mejor partición de los datos se obtiene con dos grupos (K=2), según el criterio de silhouette (0.46), lo que indica una separación moderada entre los clusters.

Este resultado sugiere la existencia de dos perfiles diferenciados de delanteros dentro de la muestra analizada.

A partir de la construcción de un indicador compuesto de rendimiento ofensivo, se identifica el cluster con mayor nivel de desempeño, el cual agrupa a los jugadores con mayor impacto en términos de generación y finalización.

Se mostrará el resultado de los 20 jugadores con mayor score:

Name	Squad	Age	top_score
Ousmane Dembele	Paris S-G	27.0	2,84E+15
Mateo Retegui	Atalanta	25.0	1,94E+16
Bradley Barcola	Paris S-G	21.0	1,69E+16
Omar Marmoush	Eint Frankfurt	25.0	1,59E+16
Alexander Isak	Newcastle Utd	24.0	1,52E+15
Serhou Guirassy	Dortmund	28.0	1,50E+16
Hugo Ekitike	Eint Frankfurt	22.0	1,47E+15
Leroy SanÃ©	Bayern Munich	28.0	1,35E+16
Georges Mikautadze	Lyon	23.0	1,15E+16
Riccardo Orsolini	Bologna	27.0	0.9412262937266955
Yoane Wissa	Brentford	27.0	0.9267329830030426
Luis DÃaz	Liverpool	27.0	0.9008293265575172
Ollie Watkins	Aston Villa	28.0	0.8504723787432799
Jonathan David	Lille	24.0	0.7603668146805855
Lamine Yamal	Barcelona	17.0	0.7572504351305571
Bryan Mbeumo	Brentford	24.0	0.651353934129383
Cody Gakpo	Liverpool	25.0	0.527412221278003
Tim Kleindienst	Gladbach	28.0	0.5167900860883025
Lautaro MartÃnez	Inter	26.0	0.5059731586487517

Entre los jugadores destacados en este grupo se encuentran perfiles diversos, combinando delanteros con alta capacidad de finalización (como Isak o Guirassy) con jugadores más orientados a la generación y progresión (como Dembélé o Barcola).

5.4 PCA (Análisis de componentes principales)

Con el objetivo de visualizar la estructura de los datos y evaluar la separación entre los clusters obtenidos, se aplica un Análisis de Componentes Principales (PCA). Esta técnica permite reducir la dimensionalidad del conjunto de variables manteniendo la mayor parte de la varianza explicada, facilitando la representación gráfica de los jugadores en un espacio bidimensional. Los resultados muestran que los clusters identificados presentan una separación razonable, lo que refuerza la validez del modelo de clustering aplicado.

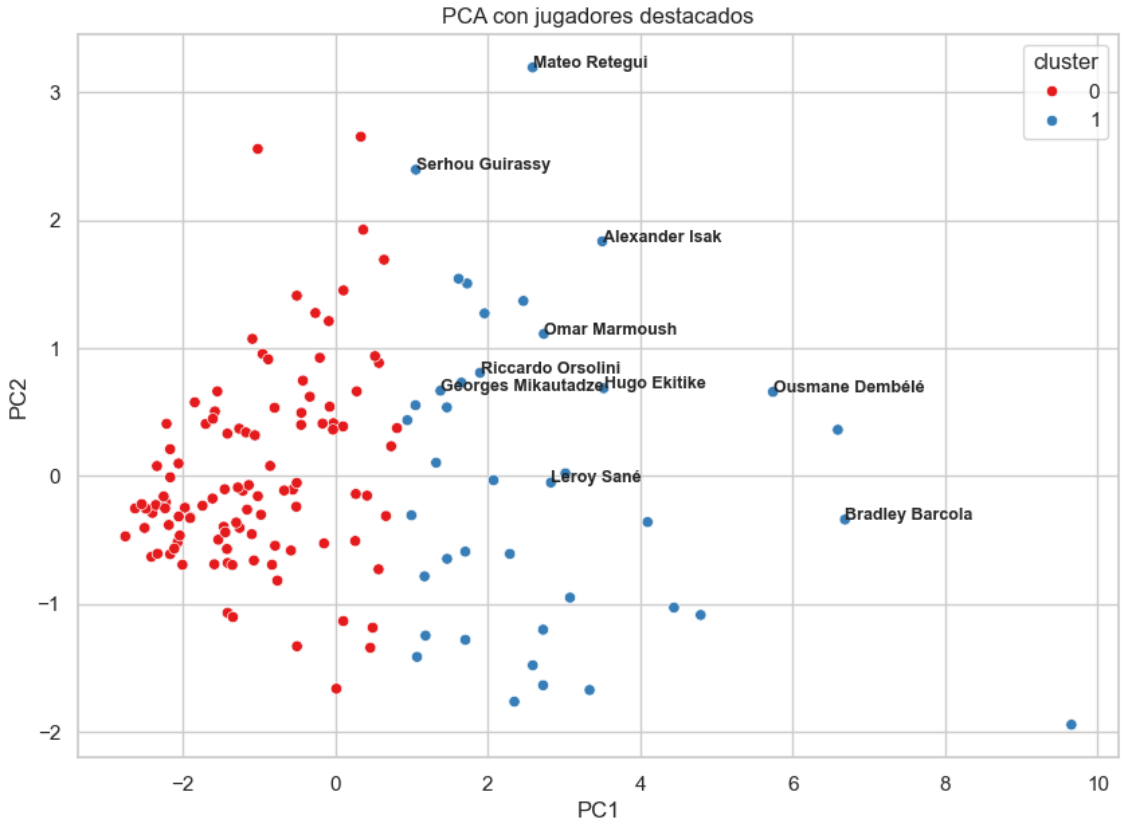

La representación en el espacio PCA muestra que la separación entre los jugadores se produce principalmente a lo largo del eje horizontal, mientras que el eje vertical introduce diferencias adicionales en el tipo de perfil ofensivo.

Por otro lado, se detectó aquellas variables que explican más cada componente:

Cargas de las variables en PCA:

Variables	PC1	PC2
PrgR	0.449832	-0.099891
xAG	0.446500	-0.032294
PrgP	0.439276	-0.144228
PrgC	0.413115	-0.407006
Ast	0.405336	0.138325
Gls	0.265263	0.885093

El análisis de las cargas de las variables permite interpretar estas dimensiones, observándose que la primera componente está asociada principalmente a métricas de progresión y generación, mientras que la segunda componente está dominada por la variable de goles. En este sentido, valores elevados en el componente 2 se asocian a perfiles más orientados al gol, mientras que valores más bajos reflejan jugadores con menor capacidad goleadora o con un perfil más orientado a la generación de juego.

6. Conclusiones

En conjunto, el análisis realizado permite identificar la existencia de distintos perfiles ofensivos dentro del grupo de delanteros, no solo en términos de nivel de rendimiento, sino también en cuanto al tipo de contribución que realizan en el juego. Por un lado, se observan jugadores con un perfil más orientado a la finalización, caracterizados por valores elevados en la segunda componente principal, lo que refleja una mayor capacidad goleadora y un rol más cercano al delantero “killer”. Por otro lado, aparecen perfiles con mayor peso en la primera componente principal, asociados a métricas de progresión y generación, que representan delanteros con una participación más activa en la construcción del juego ofensivo.

Asimismo, el análisis pone de manifiesto la existencia de perfiles híbridos, que combinan capacidad de finalización con contribución en la generación y progresión, situándose en zonas intermedias del espacio PCA. Estos jugadores representan perfiles especialmente completos y versátiles dentro del contexto ofensivo.

En este sentido, el modelo no identifica un único tipo de delantero óptimo, sino que evidencia que el rendimiento ofensivo puede manifestarse a través de diferentes perfiles. Por ello, la elección del jugador más adecuado no depende exclusivamente de su posición en el ranking o en el espacio PCA, sino del encaje táctico y de las necesidades específicas del equipo.

De este modo, la decisión final recae en la dirección deportiva, que deberá determinar si el equipo requiere un perfil más finalizador, orientado al gol, o un jugador con mayor capacidad de generación y participación en el juego, en función del modelo de juego y del contexto competitivo.